

8. Obdelava slik



Slikovna informatika



Vsebina



- Modeliranje in ocenjevanje šuma
- Filtriranje v prostoru slike
 - Osnove filtriranja
 - Glajenje in ostrenje slik
 - Statistično filtriranje
 - Prilagodljivo filtriranje
 - Morfološko filtriranje

Modeliranje šuma



- Šum je naključni pojav:
 - odvisen od postopka zajemanja slik
 - največkrat je posledica termičnih in kvantnih pojavov
- Predpostavimo, da je šum neodvisen od prostorskih koordinat in sivinskih vrednosti
- Šum je naključna spremenljivka Z , določena s funkcijo gostote verjetnosti $p(z)$

Najpogostejše vrste šuma

- Gaussov šum
- Rayleighov šum
- Erlangov šum
- Eksponentni šum
- Uniformni šum
- Impulzni šum
- Poissonov šum



Vrste šuma

Gaussov šum

$$p(z) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{z-\mu}{\sigma}\right)^2}$$

Rayleighov šum

$$p(z) = \begin{cases} \frac{2}{b}(z-a)e^{-\frac{(z-a)^2}{b}} & \text{za } z \geq a \\ 0 & \text{za } z < a \end{cases} \quad \mu = a + \sqrt{\frac{\pi b}{4}} \quad \sigma = \sqrt{\frac{b(4-\pi)}{4}}$$

Erlangov šum

$$p(z) = \begin{cases} \frac{a^b z^{b-1}}{(b-1)!} e^{-az} & \text{za } z \geq 0 \\ 0 & \text{za } z < 0 \end{cases} \quad \mu = \frac{b}{a} \quad \sigma = \frac{\sqrt{b}}{a}$$

Vrste šuma

Eksponentni šum

$$p(z) = \begin{cases} ae^{-az} & \text{za } z \geq 0 \\ 0 & \text{za } z < 0 \end{cases} \quad \mu = \frac{1}{a} \quad \sigma = \frac{1}{a}$$

Uniformni šum

$$p(z) = \begin{cases} \frac{1}{b-a} & \text{za } a \leq z \leq b \\ 0 & \text{drugod} \end{cases} \quad \mu = \frac{a+b}{2} \quad \sigma = \frac{b-a}{2\sqrt{3}}$$







Impulzni šum

$$p(z) = \begin{cases} P_a & \text{za } z = a \\ P_b & \text{za } z = b \\ 0 & \text{drugod} \end{cases}$$





Poissonov šum

$$p(k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t} \quad \mu = \lambda t \quad \sigma = \sqrt{\lambda t}$$

Vrste šuma



Impulzni šum



Ocenjevanje šuma



- **Vrsto in parametre šuma** ne poznamo
 → kako jih lahko ocenimo iz zajete slike?
- določimo čim večje področje zanimanja s konstantno sivinsko vrednostjo
 - določimo lokalni histogram in ustrezno relativno verjetnostno porazdelitev $p_r(z_i)$
 - vrsto šuma (obliko porazdelitve) lahko določimo tudi vizualno
 - parametre ocenimo s statističnimi cenilkami za srednjo vrednost in standardno deviacijo:

$$\mu \approx \bar{z} = \sum_{i=0}^{L-1} z_i p_r(z_i) \quad \sigma \approx s = \sqrt{\sum_{i=0}^{L-1} (z_i - \bar{z})^2 p_r(z_i)}$$


Ocenjevanje šuma



- za Gaussov šum tako dobimo oceni za oba parametra μ in σ
- za ostale vrste šuma dobimo parametra a in b z rešitvijo sistema enačb
- za npr. Rayleighov šum lahko na ta način določimo parametra a in b kot:

$$\mu = a + \sqrt{\frac{\pi b}{4}}$$


$$\sigma = \sqrt{\frac{b(4 - \pi)}{4}}$$



$$a = \mu - \sigma \sqrt{\frac{\pi}{4 - \pi}}$$

$$b = \frac{4\sigma^2}{4 - \pi}$$

Ocenjevanje šuma



$$\mu \approx \bar{z} = \sum_{i=0}^{L-1} z_i p_r(z_i)$$


$$\sigma \approx s = \sqrt{\sum_{i=0}^{L-1} (z_i - \bar{z})^2 p_r(z_i)}$$

Razprava – šum

- Kakšna je srednja vrednost in standardna deviacija impulznega šuma?
- Kako bi lahko objektivno določili vrsto šuma oz. obliko njegove verjetnostne porazdelitve?




Prostorsko filtriranje



- Filtriranje v prostoru slike je eno od najpomembnejših orodij pri obdelavi slik:
 - uporabno za zmanjševanja šuma, ostrenje, decimacijo,...
- Ime filtriranje izhaja iz klasičnega filtriranja v frekvenčnem prostoru
 - prepuščanje določenih frekvenc
- Podobne operacije lahko izvajamo tudi v prostoru slike:
 - transformacija v frekvenčni prostor ni potrebna
 - bolj enostavno, pregledno in lažje izvedljivo
 - nudi še številne dodatne možnosti, kot je denimo nelinearno ali statistično filtriranje v prostoru slike


Osnove filtriranja

Splošni lokalni operator $g(x, y) = T(f(x, y))$




Linearni operator $g(x, y) = \sum_{i=-a}^a \sum_{j=-b}^b w(i, j) f(x+i, y+j)$

Širitev slike z ekstrapolacijo



Glajenje slik



- Filtriranje se najpogosteje uporablja za **glajenje** in **zmanjševanje šuma**
- Uporaba glajenja:
 - odstranjevanje manjših nepravilnosti
npr. pred razgradnjo večjih objektov
 - povezovanje manjših prekinitev linij in krivulj
 - decimacija slik
- Šum opravljamo z linearnim in nelinearnim filtriranjem



Glajenje s povprečenjem

Aritmetično povprečje:

- za odpravljanje manjših nepravilnosti
- nizkopasovno filtriranje

$$g(x, y) = \frac{1}{9} \sum_{i=-1}^1 \sum_{j=-1}^1 f(x-i, y-j)$$

Navadno
povprečje

$\frac{1}{9} \times$

1	1	1
1	1	1
1	1	1

Uteženo povprečje

- navadno bolj utežimo središče filtra

$$g(x, y) = \frac{\sum_{i=-a}^a \sum_{j=-b}^b w(i, j) f(x-i, y-j)}{\sum_{i=-a}^a \sum_{j=-b}^b w(i, j)}$$

Uteženo
povprečje

$\frac{1}{16} \times$


1	2	1
2	4	2
1	2	1

Gaussov
filter


0,01	0,08	0,01
0,08	0,64	0,08
0,01	0,08	0,01

Glajenje s povprečenjem


Originalna slika



Gaussov filter 3×3



Gaussov filter 7×7



Glajenje s povprečenjem

Geometrično povprečje:

- MN -ti koren iz produkta vseh MN sivinskih vrednosti znotraj domene filtra
- nelinearen operator

$$g(x, y) = \left(\prod_{i=-a}^a \prod_{j=-b}^b f(x-i, y-j) \right)^{\frac{1}{MN}}$$

Harmonično povprečje:

- učinkovito za svetli impulzni šum (sol) in ostale vrste шумov
- neučinkovito za temni impulzni šum (poper)
- nelinearen operator

$$g(x, y) = \frac{MN}{\sum_{i=-a}^a \sum_{j=-b}^b \frac{1}{f(x-i, y-j)}}$$

Nasprotno harmonično povprečje:

- Q = stopnja filtra: $Q > 0$ učinkovito za temni impulzni šum (poper), sicer za svetlega (sol)
- za $Q = 0$ dobimo aritmetično povprečje
- za $Q = -1$ pa harmonično povprečje

$$g(x, y) = \frac{\sum_{i=-a}^a \sum_{j=-b}^b (f(x-i, y-j))^{Q+1}}{\sum_{i=-a}^a \sum_{j=-b}^b (f(x-i, y-j))^Q}$$

Glajenje?



Ostrenje slik



- Glavni namen ostrenja (*sharpening*):
 - **poudariti prehode** med različno svetlimi področji
- Povprečenje je analogno prostorski integraciji
- Ostrenje je analogno prostorski diferenciaciji oz. odvajanju sivinskih vrednosti:
 - **poudarja robove** in druge **velike spremembe** sivin
 - poudari **tudi šum!**
 - duši področja s konstantnimi in počasi spreminjajočimi se vrednostmi



Ostrenje slik

➤ Odvodi digitalne funkcije so **definirani z diferencami**:


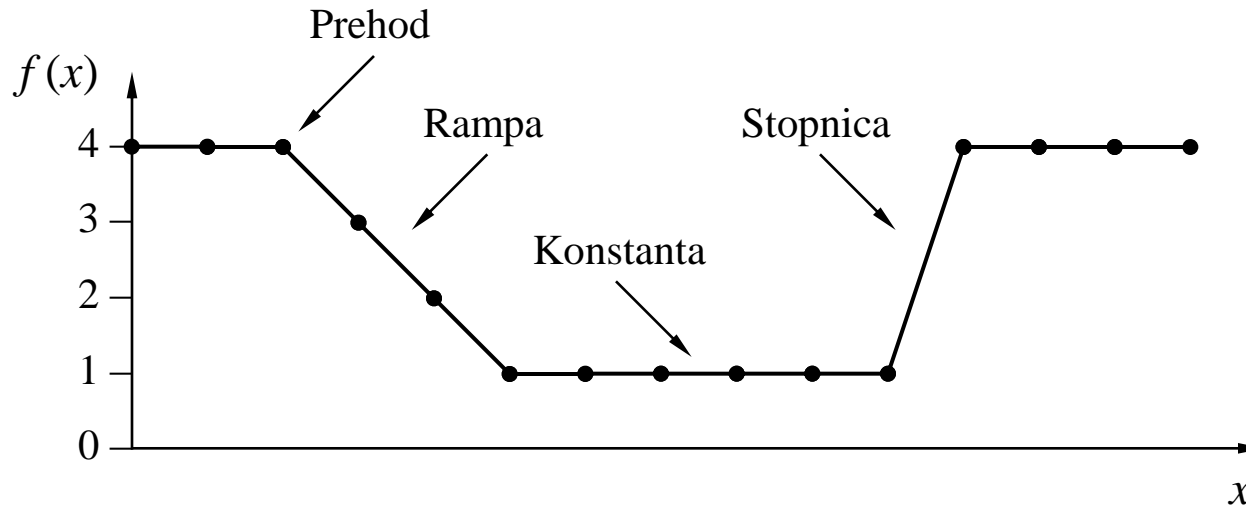
- za prvi odvod funkcije zahtevamo:
 - da ima vrednost nič na področjih s konstantno vrednostjo ter
 - da ima pozitivno oz. negativno vrednost na področjih, kjer se vrednost funkcije povečuje oz. zmanjšuje
- za drugi odvod funkcije zahtevamo:
 - da ima vrednost nič na področjih s konstantno vrednostjo in na področjih ramp ter
 - da ima pozitivno oz. negativno vrednost na področjih, kjer se vrednost funkcije neenakomerno povečuje oz. zmanjšuje

➤ Digitalne funkcije imajo končne vrednosti:

- zato so tudi največje možne spremembe njihovih vrednosti končne
- najkrajša razdalja na kateri se sprememba lahko zgodi je določena z vzorčno periodo



Odvajanje digitalne funkcije



Prvi odvod 2D slike – gradient

- Za 2D funkcijo $f(x,y)$ ga zapišemo v obliki stolpnega vektorja (linearna operacija):

$$\nabla f(x, y) = \text{grad}[f(x, y)] = \mathbf{g}(x, y) = \begin{bmatrix} g_x(x, y) \\ g_y(x, y) \end{bmatrix} = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix}$$

- Dobimo **vektorsko sliko** gradienta $\mathbf{g}(x,y)$, ki kaže v smeri največje spremembe funkcije $f(x,y)$
- Velikost oz. **sliko gradienta** izračunamo kot (nelinearna operacija):

$$G(x, y) = \text{amp}[\nabla f(x, y)] = \sqrt{g_x^2(x, y) + g_y^2(x, y)}$$

- **Sobelov operator** →
 - poudarjanje robov
 - razgradnja
 - kvantitativna analiza

$$g_x$$

-1	0	1
-2	0	2
-1	0	1



$$g_y$$

-1	-2	-1
0	0	0
1	2	1







Sobelov operator – primeri

 $f(x,y)$

 $G(x,y)$

 $g_x(x,y)$

 $g_y(x,y)$


Sobelov operator – primeri

 $f(x,y)$  $G(x,y)$ 

Drugi odvod 2D slike

- Najenostavnejši operator za drugi odvod je **Laplaceov operator**:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

- Za digitalno 2D funkcijo ga izrazimo z diferencami:

$$\frac{\partial^2 f}{\partial x^2} = f(x+1, y) - 2f(x, y) + f(x-1, y)$$

$$\frac{\partial^2 f}{\partial y^2} = f(x, y+1) - 2f(x, y) + f(x, y-1)$$

$$\nabla^2 f(x, y) = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y)$$

0	1	0
1	-4	1
0	1	0

Navadno dodamo še diagonalne člene za 45° izotropnost →




1	1	1
1	-8	1
1	1	1

Ostrenje z drugim odvodom

- Vhodni sliki $f(x,y)$ odštejemo uteženo sliko drugega odvoda:

$$g(x, y) = f(x, y) - c \left[\nabla^2 f(x, y) \right]$$

- Konstanta c določa stopnjo ostrenja.

 $f(x,y)$  $g(x,y)$ 

Ostrenje z maskiranjem


- Masko dobimo tako, da vhodni sliki $f(x,y)$ odštejemo njeno zglajeno verzijo (*unsharp masking*):

$$m(x, y) = f(x, y) - F(f(x, y))$$



- Sliko maske $m(x,y)$ dodamo vhodni sliki:

$$g(x, y) = f(x, y) + c \cdot m(x, y)$$



- Stopnjo ostrenja določa konstanta c
- Digitalni filter F pa določa območje ostrenja:
→ lokalno oz. globalno ostrenje (odvisno npr. od σ)



Maskiranje neostrih področij



Maskiranje neostrih področij











Maskiranje neostrih področij

$$f(x,y)$$

$$F(f(x,y))$$


$$m(x,y) = f(x,y) - F(f(x,y)) \quad g(x,y) = f(x,y) + m(x,y)$$



Maskiranje neostrih področij

 $f(x,y)$  $g(x,y)$

Maskiranje neostrih področij



Statistično filtriranje

- Sivinske vrednosti pikslov znotraj filtra **uredimo po velikosti** (od največje do najmanjše)
- **Urejeno statistično filtriranje je nelinearno in robustno:**
 - neobčutljivo na nepravilnosti slik (*outliers*)






Statistično filtriranje – mediana

- Mediana je sredinska vrednost v urejenem nizu n vrednosti:
 z_1, z_2, \dots, z_n , polovica vrednosti je manjših, polovica pa večjih

$$\text{Med} = \begin{cases} z_{(n+1)/2} & \text{ko je } n \text{ liho število} \\ \frac{z_{n/2} + z_{n/2+1}}{2} & \text{ko je } n \text{ sodo število} \end{cases}$$


$$g(x, y) = \text{Med}_{i=-a \dots a, j=-b \dots b} [f(x-i, y-j)]$$

- Mediana je bolj robustna kot povprečje
- Primernejša za nesimetrične porazdelitve




Statistično filtriranje – mediana


Original sol in poper



Povprečje 3×3




Mediana 3×3




Primerjava Gauss – mediana


Original




Poper 10 %




Gauss 5 × 5




Mediana 5 × 5




Poper 20 %



Gauss 5 × 5



Mediana 5 × 5



Druge statistike

- Filter **maksimalne** in **minimalne** vrednosti:

$$g(x, y) = \underset{i=-a \dots a, j=-b \dots b}{\text{Maks}} [f(x-i, y-j)]$$

$$g(x, y) = \underset{i=-a \dots a, j=-b \dots b}{\text{Min}} [f(x-i, y-j)]$$


- Filter **srednje vrednosti** (*midpoint filter*):

$$g(x, y) = \frac{\underset{i=-a \dots a, j=-b \dots b}{\text{Maks}} [f(x-i, y-j)] + \underset{i=-a \dots a, j=-b \dots b}{\text{Min}} [f(x-i, y-j)]}{2}$$

- Filter **povprečnih obrezanih vrednosti** (*alpha-trimmed mean filter*)

$$g(x, y) = \frac{1}{MN - d} \sum_{i=-a}^a \sum_{j=-b}^b f_p(x-i, y-j)$$

- Odstranimo ustrezen delež skrajnih vrednosti:
 - za $d = 0 \rightarrow$ dobimo aritmetično povprečje
 - za $d = MN - 1 \rightarrow$ dobimo medianin filter



Prilagodljivo filtriranje



- Spreminjamo lastnosti filtrov glede na statistične lastnosti slike (*adaptive filtering*)
- Izboljšamo lastnosti filtrov, poveča pa se kompleksnost filtriranja
- Npr. če poznamo standardno deviacijo šuma σ_n lahko določimo prilagodljivi filter kot:

$$g(x, y) = f(x, y) - \left(\frac{\sigma_n}{\sigma_f} \right)^2 [f(x, y) - \mu_f]$$

kjer je μ_f povprečje in σ_f standardna deviacija slike znotraj filtra

- Bolj zgladi sliko na homogenih področjih $\rightarrow \sigma_f \approx \sigma_n$
- Manj pa na prehodih med homogenimi področji $\rightarrow \sigma_f > \sigma_n$
- Številni drugi načini prilagodljivega filtriranja:
 - npr. s spreminjanjem velikosti filtra glede na sliko

Morfološko filtriranje

- Vrednost piksla izhodne slike določimo na podlagi pravila, ki ga določa binarni **strukturni element** $b(x,y)$ s svojo velikost in obliko:

1	1	1
1	1	1
1	1	1

0	1	0
1	1	1
0	1	0

1
1
1

1	1	1
---	---	---

0	0	1	0	0
0	1	1	1	0
1	1	1	1	1
0	1	1	1	0
0	0	1	0	0

- Velikost in obliko strukturnega elementa določimo glede na namen filtriranja



Morfološko filtriranje

- Osnovni operaciji morfološkega filtriranja sta **erozija** in **dilacija**, ki ju za vhodno sliko $f(x,y)$ in binarni strukturni element $b(x,y)$ lahko določimo kot:

Erozija E oz. \ominus $(f \ominus b)(x, y) = \min_{\forall i,j} \{f(x - j, y - j) \cdot b(i, j)\}$

Dilacija D oz. \oplus $(f \oplus b)(x, y) = \max_{\forall i,j} \{f(x - j, y - j) \cdot b(i, j)\}$


- S kombinacijo erozije in dilacije dobimo operaciji morfološkega **odpiranja** in **zapiranja** kot:

Odpiranje O oz. \circ $f \circ b = (f \ominus b) \oplus b$



Zapiranje Z oz. \bullet $f \bullet b = (f \oplus b) \ominus b$

Erozija in dilacija

Strukturni
element



Zapiranje = Dilacija + Erozijs




Odpiranje = Eroziija + Dilacija




Original

Eroziija




Dilacija

Odprto
E+D



Zapiranje in odpiranje






Morfološko binarno filtriranje



Morfološko binarno filtriranje



Morfološko sivinsko filtriranje



Morfološko binarno filtriranje





Razprava – filtriranje

- Kakšne vrednosti koeficientov bi moral imeti digitalni filter, da bi dal največji odziv na robovih pod kotom 45° ?
- Kako bi lahko določili primeren delež d skrajnih sivinskih vrednosti (ang. *outliers*), ki določa statistični filter obrezanih vrednosti?
- Kako bi lahko izvedli prilagodljivo filtriranje s spreminjanjem velikosti domene filtra glede na lokalne statistične lastnosti slike?
- Ali je smiselno operaciji erozije in dilacije v zaporedju poljubno kombinirati, tako v številu ponovitev kot v vrstnem redu?